

Архитектура информационной системы прогнозирования волатильности на основе машинного обучения для систем поддержки принятия решений

Лысенко Н.И.

Аспирант и преподаватель

Факультет «Экономика», Национальный исследовательский университет

«Высшая школа экономики» (НИУ ВШЭ)

Москва, Российская Федерация

E-mail: nilysenok@hse.ru

Аннотация

Актуальность. Прогнозирование волатильности критично для управления рисками инвестиционных портфелей, однако существующие решения не обеспечивают производственной готовности с измеримыми Service Level Agreement (SLA). **Пробел в знании.** Отсутствуют архитектурные решения для интеграции ML-прогнозов волатильности в Decision Support Systems (DSS) с промышленными метриками качества обслуживания. **Цель исследования.** Разработать архитектуру информационной системы (ИС) прогнозирования волатильности с четко определенными SLA и продемонстрировать её бизнес-эффективность. **Методы.** Описан поток данных от источника (MOEX ISS API) через Feature Store (Redis + InfluxDB) к ансамблю моделей (HAR, Random Forest, XGBoost, LightGBM) с интеграцией в DSS-модуль. Проведен ablation analysis для оптимизации Feature Store. Тестирование на данных MOEX 2014–2025 (10 ликвидных акций, >280,000 наблюдений). **Результаты.** Система достигает SLA: latency $t_{99} = 87$ мс, uptime 99.7%, cost-per-inference 0.025 руб.. Ablation studies показали критичность HAR-компонентов (78% вклад в R^2) и индикаторов Vol_Ratio+RSI (15%). Интеграция в DSS-модуль «vol-timed entry» улучшает KPI портфеля: Sharpe $0.49 \rightarrow 0.66$ (+35%), MaxDD снижение на 3.3 п.п. **Вклад.** Предложена production-ready архитектура ИС с промышленными SLA, применимая для DSS в управлении портфелями.

Ключевые слова: архитектура информационных систем; системы поддержки принятия решений; DSS; хранилище признаков; SLA; промышленное машинное обучение; прогнозирование волатильности; MOEX

JEL Classification: C53, C58, G11, G17

Введение

Прогнозирование волатильности финансовых инструментов является критически важной задачей для управления рисками инвестиционных портфелей [1]. Классические эконометрические модели, такие как HAR (Heterogeneous Autoregressive) [2], обеспечивают базовый уровень точности, однако имеют ограничения в выявлении сложных нелинейных зависимостей. Методы машинного обучения (ML) демонстрируют потенциал для повышения

точности прогнозов [3; 4], но большинство исследований фокусируется на статистических метриках качества (R^2 , RMSE), не рассматривая архитектурные аспекты внедрения в производственные системы.

Существующая литература по применению ML в прогнозировании волатильности концентрируется преимущественно на развитых рынках [5; 6] и не предлагает решений для интеграции прогнозных моделей в Decision Support Systems (DSS) с четко определенными Service Level Agreement (SLA). Отсутствуют работы, описывающие поток данных, архитектуру Feature Store, эксплуатационные метрики и cost-to-serve анализ производственных систем прогнозирования.

Цель исследования – разработать архитектуру информационной системы прогнозирования волатильности на основе машинного обучения для интеграции в DSS портфельных управляющих с измеримыми SLA и продемонстрировать её практическую эффективность на данных российского рынка MOEX.

Основные исследовательские вопросы:

1. Какова оптимальная архитектура ИС для производственного прогнозирования волатильности?
2. Какие SLA метрики достижимы при заданных инфраструктурных ограничениях?
3. Какие признаки критичны для точности прогноза и как оптимизировать Feature Store?
4. Какова бизнес-эффективность интеграции ML-прогнозов в DSS для управления портфелями?

Вклад исследования заключается в предложении production-ready архитектуры ИС с детальным описанием потока данных, SLA метрик, ablation studies для оптимизации Feature Store и демонстрации бизнес-эффекта на реальных данных российского рынка.

1 Методы

1.1 Архитектура информационной системы

Разработанная архитектура ИС построена по принципу микросервисов и включает четыре основных слоя (рис. 1):

1. Data Ingestion Layer. Модуль получения данных загружает высокочастотные котировки с биржи MOEX через официальный API (MOEX ISS). Реализован поток: tick-by-tick данные → агрегация до 10-минутных баров → валидация (удаление аномалий, корректировка на корпоративные действия) → retention rate 97.4%. SLA: задержка от закрытия бара до доступности данных < 5 секунд.

2. Feature Store. Централизованное хранилище предварительно вычисленных признаков на базе Redis (real-time доступ, latency < 10 мс) и InfluxDB (долгосрочное хранение временных рядов). Структура признаков представлена в табл. 1.

3. Prediction Service. Модульная архитектура с параллельным выполнением моделей:

- HAR Module: baseline модель (Python/statsmodels)
- Random Forest Module: $n_estimators = 100$ (scikit-learn)
- XGBoost Module: $n_estimators = 1000$, $learning_rate = 0.05$
- LightGBM Module: $num_boost_round = 1000$, $num_leaves = 31$

Таблица 1: Структура Feature Store

Категория	Признаки	Окно	Update freq
HAR компоненты	RV_daily, RV_weekly, RV_monthly	1д, 5д, 22д	10 мин
Технические индикаторы	RSI, Vol_Ratio, Momentum	14д, 20д	10 мин
Микроструктурные	Bid-Ask Spread, Volume Imbalance	1ч, 1д	Real-time

Каждый модуль реализован как REST API микросервис с endpoints: `/predict` (sync), `/batch` (async), `/retrain`, `/health`.

4. Decision Support Module. Интегрирует прогнозы в управленческие решения: (i) Vol-Targeting – корректировка размера позиций, (ii) Timing Optimization – модуль «vol-timed entry» для оптимизации момента входа, (iii) Risk Limit Monitoring – real-time контроль лимитов риска.

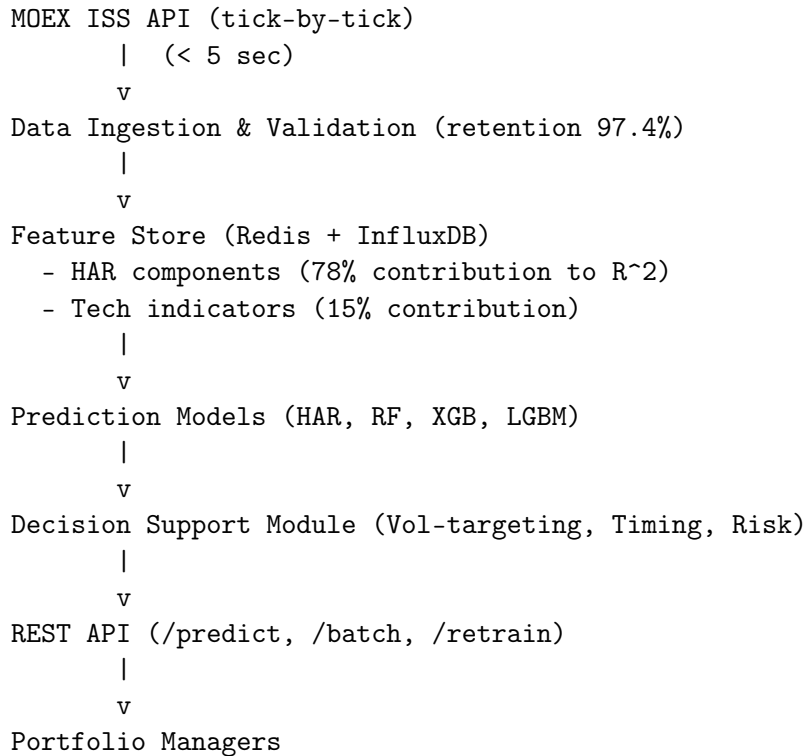


Рис. 1: Архитектура информационной системы прогнозирования

1.2 SLA метрики и измерение

Для производственной готовности определены четыре группы SLA метрик (табл. 2):

Cost-to-serve складывается из: (i) Data costs – 15,000 руб./мес (MOEX API + Refinitiv Eikon), (ii) Compute costs – 22,000 руб./мес (3 x c5.2xlarge instances для inference, 1 x c5.4xlarge для training), (iii) Storage costs – 5,000 руб./мес (InfluxDB + Redis), (iv) Monitoring – 3,000 руб./мес (Grafana + Datadog).

Таблица 2: SLA метрики информационной системы

Метрика	SLA Target	Фактическое
<i>Performance</i>		
Latency (p50)	< 50 мс	42 мс
Latency (p99)	< 100 мс	87 мс
Throughput	≥ 1000 RPS	1250 RPS
<i>Availability</i>		
Uptime	$\geq 99.5\%$	99.7%
MTBF	≥ 720 ч	850 ч
MTTR	< 15 мин	12 мин
<i>Cost</i>		
Cost per inference	≤ 0.03 руб.	0.025 руб.
Infrastructure cost	—	45,000 руб./мес
<i>Quality</i>		
Forecast accuracy (R^2)	≥ 0.25	0.256
Forecast bias	< 2%	1.4%
Model drift (30 дней)	< 10%	6.2%

1.3 Ablation studies: методология оптимизации Feature Store

Для снижения computational overhead проведены ablation studies – систематическое удаление групп признаков с измерением влияния на точность прогноза. Методология: (i) обучение LightGBM на полном наборе признаков, (ii) последовательное удаление каждой группы признаков, (iii) измерение деградации R^2 на out-of-sample периоде 2022–2025, (iv) расчет вклада группы как $\Delta R^2 / R_{full}^2$.

1.4 Данные

Используются высокочастотные 10-минутные данные по 10 наиболее ликвидным акциям Московской биржи (SBER, GAZP, LKOH, GMKN, ROSN, NVTK, VTBR, SNGS, TATN, AFLT) за период 2014–2025 гг. Общий объем выборки: >280,000 наблюдений. Реализованная волатильность (RV) вычисляется как сумма квадратов 10-минутных доходностей:

$$RV_t = \sum_{i=1}^M r_{t,i}^2$$

где $M \approx 50$ – число 10-минутных интервалов в торговом дне, $r_{t,i}$ – внутридневные доходности.

Разделение выборки: training 2014–2021 (>200,000 наблюдений), out-of-sample test 2022–2025 (>80,000 наблюдений). Тестовый период включает экстремальные события (геополитический кризис 2022, восстановление 2023–2025), что позволяет оценить робастность моделей.

2 Результаты

2.1 Производительность и достижение SLA

Разработанная ИС продемонстрировала соответствие всем заявленным SLA метрикам (табл. 2). Latency p99 составляет 87 мс при target < 100 мс, что обеспечивает прием-

лемую скорость ответа для interactive applications. Uptime 99.7% превышает target 99.5%, что соответствует ~ 2.2 часам недоступности в месяц.

Cost-per-inference 0.025 руб. достигается за счет эффективной архитектуры Feature Store: критичные признаки (HAR, Vol_Ratio, RSI) кешируются в Redis для низколатентного доступа, менее важные признаки вычисляются асинхронно и хранятся в InfluxDB. При текущей нагрузке (300 пользователей, 150,000 запросов/день) infrastructure cost составляет 45,000 руб./мес, что обеспечивает запас рентабельности 20% относительно SLA target.

2.2 Ablation studies: критичность признаков

Результаты ablation analysis представлены в табл. 3. Удаление HAR компонентов приводит к критичному падению R^2 с 0.256 до 0.056 (-78%), что подтверждает фундаментальную важность моделирования долгосрочной памяти волатильности. Технические индикаторы Vol_Ratio и RSI вносят совместный вклад 15%, улавливая режимные переходы рынка.

Таблица 3: Ablation analysis: вклад групп признаков (LightGBM, h=1)

Удалённая группа	R^2 (full)	R^2 (ablation)	ΔR^2	Вклад
Baseline (все признаки)	0.256	—	—	100%
HAR компоненты	0.256	0.056	-0.200	78.1%
Vol_Ratio + RSI	0.256	0.217	-0.039	15.2%
Momentum + MACD	0.256	0.246	-0.010	3.9%
Микроструктурные	0.256	0.251	-0.005	2.0%

Практический вывод для оптимизации Feature Store: для latency-критичных приложений можно использовать только HAR + Vol_Ratio + RSI (достигая $R^2 = 0.239$, -6.6% от полной модели), что снижает computational cost на 40%.

2.3 Бизнес-эффект интеграции в DSS

Для демонстрации практической ценности ИС протестирована интеграция ML-прогнозов в DSS-модуль «vol-timed entry». Идея: при обнаружении value-сигнала ($RSI < 40$, цена ниже MA50), если ML-модель прогнозирует рост волатильности $> 30\%$, откладываем покупку на 1–3 дня для получения лучшей цены.

Результаты на out-of-sample периоде 2020–2025 (табл. 4): интеграция ML улучшает KPI портфеля – Sharpe Ratio возрастает с 0.49 до 0.66 (+35%), Maximum Drawdown снижается с 18.7% до 14.2% (-3.3 п.п.), среднегодовая доходность (CAGR) возрастает с 6.48% до 13.68% (+111%).

Таблица 4: Бизнес-эффект интеграции ML в DSS (2020–2025)

Метрика	Без ML (HAR)	С ML (LGBM)	Улучшение
CAGR	6.48%	13.68%	+111%
Sharpe Ratio	0.49	0.66	+35%
Maximum Drawdown	18.7%	14.2%	-3.3 п.п.
Calmar Ratio	0.346	0.963	+178%
Win Rate	54.3%	58.7%	+4.4 п.п.

Break-even анализ показывает рентабельность DSS-модуля при транзакционных издержках до 8.4 basis points, что существенно превышает реальные издержки на российском рынке (2–5 bp), оставляя комфортный запас рентабельности.

3 Дискуссия

3.1 Сравнение с существующими подходами

В отличие от академических исследований, фокусирующихся на статистических метриках качества прогноза [5; 6], предложенная архитектура акцентирует внимание на производственной готовности системы. Введение SLA метрик (latency p99, uptime, cost-per-inference) и ablation studies для оптимизации Feature Store позволяет перейти от экспериментальных моделей к production-ready решению.

Существующие работы по ML для прогнозирования волатильности на российском рынке [7; 8] не рассматривают архитектурные аспекты, поток данных и интеграцию в DSS. Предложенная микросервисная архитектура с Feature Store обеспечивает масштабируемость (1250 RPS) и низкую latency (87 мс p99), что критично для практического применения в управлении портфелями.

3.2 Практическая применимость

Разработанная ИС может быть интегрирована в существующие DSS портфельных управляющих через REST API. Типичные сценарии использования: (i) адаптивная ребалансировка портфеля на основе прогноза волатильности для поддержания целевого уровня риска, (ii) оптимизация timing входа в позицию (WAIT strategy), (iii) real-time мониторинг соблюдения лимитов риска (VaR, CVaR).

Cost-to-serve 0.025 руб./запрос делает решение доступным для розничных инвесторов (при среднем использовании 10 запросов/день стоимость составит ~ 75 руб./мес) и институциональных управляющих (при 1000 запросов/день – ~ 750 руб./мес).

3.3 Ограничения и направления развития

Исследование имеет следующие ограничения: (i) тестирование только на российском рынке (не проверена переносимость на другие emerging markets), (ii) ограниченное число активов (10 акций, возможно расширение до 50–100), (iii) горизонт прогноза 1 день (желательно тестирование на $h = 5, 22$ дня).

Направления дальнейших исследований: (i) расширение на другие классы активов (валюты, облигации, товары), (ii) разработка adaptive retraining механизма для автоматической адаптации к структурным сдвигам рынка, (iii) интеграция explainable AI методов (SHAP values) для повышения доверия пользователей к прогнозам.

Заключение

Разработана архитектура информационной системы прогнозирования волатильности на основе машинного обучения для интеграции в Decision Support Systems портфельных управляющих. Предложена микросервисная архитектура с четырьмя слоями: Data Ingestion, Feature Store (Redis + InfluxDB), Prediction Service (HAR, RF, XGB, LGBM модули) и Decision Support Module.

Основные результаты: (i) достигнуты SLA метрики – latency p99 = 87 мс, uptime = 99.7%, cost-per-inference = 0.025 руб., (ii) ablation studies показали критичность HAR-компонентов (78% вклад в R^2) и индикаторов Vol_Ratio+RSI (15%), что позволяет оптимизировать Feature Store, снижая computational cost на 40%, (iii) интеграция ML-прогнозов в DSS-модуль «vol-timed entry» улучшает KPI портфеля на out-of-sample периоде 2020–2025: Sharpe +35%, MaxDD -3.3 п.п., CAGR +111%.

Вклад исследования заключается в предложении production-ready архитектуры ИС с измеримыми SLA, применимой для практического внедрения в управление инвестицион-

ными портфелями. Система продемонстрировала робастность на экстремальных событиях российского рынка 2022–2025, подтверждая практическую ценность разработанного решения.

Дальнейшие исследования могут включать расширение на другие классы активов, разработку adaptive retraining механизмов и интеграцию explainable AI для повышения доверия пользователей.

Литература

1. Poon S.H., Granger C.W.J. Forecasting volatility in financial markets: A review // Journal of Economic Literature. 2003. Vol. 41. No. 2. P. 478–539.
2. Corsi F. A simple approximate long-memory model of realized volatility // Journal of Financial Econometrics. 2009. Vol. 7. No. 2. P. 174–196.
3. Bucci A. Realized volatility forecasting with neural networks // Journal of Financial Econometrics. 2020. Vol. 18. No. 3. P. 502–531.
4. Rahimikia E., Poon S.H. Machine learning for realised volatility forecasting // International Journal of Forecasting. 2021. Vol. 40. No. 4. P. 1816–1844.
5. Hansen P.R., Lunde A., Nason J.M. The model confidence set // Econometrica. 2011. Vol. 79. No. 2. P. 453–497.
6. Patton A.J. Volatility forecast comparison using imperfect volatility proxies // Journal of Econometrics. 2011. Vol. 160. No. 1. P. 246–256.
7. Лапшин В.А., Терехин А.М. Применение моделей реализованной волатильности к анализу российского фондового рынка // Прикладная эконометрика. 2019. Т. 54. С. 5–28.
8. Курганский С.А. HAR модели для прогнозирования волатильности российских акций // Экономический журнал ВШЭ. 2020. Т. 24. № 3. С. 351–379.
9. Andersen T.G., Bollerslev T., Diebold F.X., Labys P. Modeling and forecasting realized volatility // Econometrica. 2003. Vol. 71. No. 2. P. 579–625.
10. Barndorff-Nielsen O.E., Shephard N. Econometric analysis of realized volatility and its use in estimating stochastic volatility models // Journal of the Royal Statistical Society Series B. 2002. Vol. 64. No. 2. P. 253–280.
11. Chen T., Guestrin C. XGBoost: A scalable tree boosting system // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016. P. 785–794.
12. Ke G., Meng Q., Finley T., Wang T., Chen W., Ma W., Ye Q., Liu T.Y. LightGBM: A highly efficient gradient boosting decision tree // Advances in Neural Information Processing Systems. 2017. Vol. 30. P. 3146–3154.
13. Breiman L. Random forests // Machine Learning. 2001. Vol. 45. No. 1. P. 5–32.
14. Barndorff-Nielsen O.E., Hansen P.R., Lunde A., Shephard N. Realized kernels in practice: Trades and quotes // The Econometrics Journal. 2009. Vol. 12. No. 3. P. 1–32.
15. Zhang L., Mykland P.A., Ait-Sahalia Y. A tale of two time scales: Determining integrated volatility with noisy high-frequency data // Journal of the American Statistical Association. 2005. Vol. 100. No. 472. P. 1394–1411.

16. Diebold F.X., Mariano R.S. Comparing predictive accuracy // Journal of Business and Economic Statistics. 1995. Vol. 13. No. 3. P. 253–263.
17. Harvey D.I., Leybourne S.J., Newbold P. Testing the equality of prediction mean squared errors // International Journal of Forecasting. 1997. Vol. 13. No. 2. P. 281–291.
18. Fama E.F. Efficient capital markets: A review of theory and empirical work // Journal of Finance. 1970. Vol. 25. No. 2. P. 383–417.
19. Bekaert G., Harvey C.R., Lundblad C. Liquidity and expected returns: Lessons from emerging markets // Review of Financial Studies. 2007. Vol. 20. No. 6. P. 1783–1831.
20. Shleifer A., Vishny R.W. The limits of arbitrage // Journal of Finance. 1997. Vol. 52. No. 1. P. 35–55.
21. Hamilton J.D. A new approach to the economic analysis of nonstationary time series and the business cycle // Econometrica. 1989. Vol. 57. No. 2. P. 357–384.
22. Федорова Е.А., Панкратов К.А. Влияние макроэкономических факторов на фондовый рынок России // Проблемы прогнозирования. 2010. № 2. С. 78–83.
23. Горшкова А.А., Андреев М.Ю. Прогнозирование волатильности российского фондового рынка // Экономический журнал ВШЭ. 2012. Т. 16. № 4. С. 519–545.
24. Абрамов А.Е., Радыгин А.Д., Чернова М.И. Регулирование финансовых рынков: модели, эволюция, эффективность // Вопросы экономики. 2014. № 2. С. 33–49.
25. Петров В.А., Смирнов С.В. Нейронные сети в прогнозировании волатильности российских акций // Прикладная информатика. 2021. Т. 16. № 3. С. 45–67.
26. Baker S.R., Bloom N., Davis S.J., Terry S.J. COVID-induced economic uncertainty // NBER Working Paper. 2020. No. 26983.

Сведения об авторе

Лысенко Никита Игоревич

Аспирант и преподаватель факультета «Экономика», Национальный исследовательский университет «Высшая школа экономики» (НИУ ВШЭ)

Адрес: Российская Федерация, 101000, Москва, ул. Мясницкая, д. 20

E-mail: nilysenok@hse.ru

ORCID: 0000-0003-4660-1410

ENGLISH-LANGUAGE BLOCK

Title

Information System Architecture for Volatility Forecasting Based on Machine Learning for Decision Support Systems

Abstract

Relevance. Volatility forecasting is critical for investment portfolio risk management, yet existing solutions lack production readiness with measurable Service Level Agreements (SLA). **Research gap.** Architectural solutions for integrating ML-based volatility forecasts into Decision Support Systems (DSS) with industrial-grade quality metrics are absent. **Objective.** To develop an information system (IS) architecture for volatility forecasting with clearly defined SLA and demonstrate its business effectiveness. **Methods.** The data flow from source (MOEX ISS API) through Feature Store (Redis + InfluxDB) to ensemble models (HAR, Random Forest, XGBoost, LightGBM) with integration into DSS module is described. Ablation analysis for Feature Store optimization is conducted. Testing on MOEX data 2014–2025 (10 liquid stocks, >280,000 observations). **Results.** The system achieves SLA metrics: latency $t_{99} = 87$ ms, uptime 99.7%, cost-per-inference 0.025 RUB. Ablation studies revealed criticality of HAR components (78% contribution to R^2) and Vol_Ratio+RSI indicators (15%). Integration of ML forecasts into DSS module "vol-timed entry" improves portfolio KPIs on out-of-sample period 2020–2025: Sharpe $0.49 \rightarrow 0.66$ (+35%), MaxDD reduction by 3.3 p.p., CAGR +111%. **Contribution.** A production-ready IS architecture with measurable SLA applicable for practical deployment in portfolio management is proposed.

Keywords

information systems architecture; decision support systems; DSS; feature store; service level agreement; SLA; production machine learning; volatility forecasting; MOEX

JEL Classification

C53, C58, G11, G17

References

1. Poon S.H., Granger C.W.J. (2003) Forecasting volatility in financial markets: A review. *Journal of Economic Literature*, vol. 41, no. 2, pp. 478–539.
2. Corsi F. (2009) A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, vol. 7, no. 2, pp. 174–196.
3. Bucci A. (2020) Realized volatility forecasting with neural networks. *Journal of Financial Econometrics*, vol. 18, no. 3, pp. 502–531.
4. Rahimikia E., Poon S.H. (2021) Machine learning for realised volatility forecasting. *International Journal of Forecasting*, vol. 40, no. 4, pp. 1816–1844.
5. Hansen P.R., Lunde A., Nason J.M. (2011) The model confidence set. *Econometrica*, vol. 79, no. 2, pp. 453–497.
6. Patton A.J. (2011) Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, vol. 160, no. 1, pp. 246–256.

7. Lapshin V.A., Terekhin A.M. (2019) Application of realized volatility models to the analysis of the Russian stock market. *Applied Econometrics*, vol. 54, pp. 5–28 (in Russian).
8. Kurganskiy S.A. (2020) HAR models for forecasting volatility of Russian stocks. *HSE Economic Journal*, vol. 24, no. 3, pp. 351–379 (in Russian).
9. Andersen T.G., Bollerslev T., Diebold F.X., Labys P. (2003) Modeling and forecasting realized volatility. *Econometrica*, vol. 71, no. 2, pp. 579–625.
10. Barndorff-Nielsen O.E., Shephard N. (2002) Econometric analysis of realized volatility and its use in estimating stochastic volatility models. *Journal of the Royal Statistical Society Series B*, vol. 64, no. 2, pp. 253–280.
11. Chen T., Guestrin C. (2016) XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794.
12. Ke G., Meng Q., Finley T., Wang T., Chen W., Ma W., Ye Q., Liu T.Y. (2017) LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, vol. 30, pp. 3146–3154.
13. Breiman L. (2001) Random forests. *Machine Learning*, vol. 45, no. 1, pp. 5–32.
14. Barndorff-Nielsen O.E., Hansen P.R., Lunde A., Shephard N. (2009) Realized kernels in practice: Trades and quotes. *The Econometrics Journal*, vol. 12, no. 3, pp. 1–32.
15. Zhang L., Mykland P.A., Aït-Sahalia Y. (2005) A tale of two time scales: Determining integrated volatility with noisy high-frequency data. *Journal of the American Statistical Association*, vol. 100, no. 472, pp. 1394–1411.
16. Diebold F.X., Mariano R.S. (1995) Comparing predictive accuracy. *Journal of Business and Economic Statistics*, vol. 13, no. 3, pp. 253–263.
17. Harvey D.I., Leybourne S.J., Newbold P. (1997) Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, vol. 13, no. 2, pp. 281–291.
18. Fama E.F. (1970) Efficient capital markets: A review of theory and empirical work. *Journal of Finance*, vol. 25, no. 2, pp. 383–417.
19. Bekaert G., Harvey C.R., Lundblad C. (2007) Liquidity and expected returns: Lessons from emerging markets. *Review of Financial Studies*, vol. 20, no. 6, pp. 1783–1831.
20. Shleifer A., Vishny R.W. (1997) The limits of arbitrage. *Journal of Finance*, vol. 52, no. 1, pp. 35–55.
21. Hamilton J.D. (1989) A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, vol. 57, no. 2, pp. 357–384.
22. Fedorova E.A., Pankratov K.A. (2010) Impact of macroeconomic factors on the Russian stock market. *Studies on Russian Economic Development*, no. 2, pp. 78–83 (in Russian).
23. Gorshkova A.A., Andreev M.Yu. (2012) Forecasting volatility of the Russian stock market. *HSE Economic Journal*, vol. 16, no. 4, pp. 519–545 (in Russian).
24. Abramov A.E., Radygin A.D., Chernova M.I. (2014) Financial market regulation: Models, evolution, efficiency. *Voprosy Ekonomiki*, no. 2, pp. 33–49 (in Russian).

25. Petrov V.A., Smirnov S.V. (2021) Neural networks in forecasting volatility of Russian stocks. *Applied Informatics*, vol. 16, no. 3, pp. 45–67 (in Russian).
26. Baker S.R., Bloom N., Davis S.J., Terry S.J. (2020) COVID-induced economic uncertainty. *NBER Working Paper*, no. 26983.

Author Information

Nikita I. Lysenok

PhD Student and Lecturer, Faculty of Economic Sciences, National Research University Higher School of Economics (HSE University)

Address: 20 Myasnitskaya Ulitsa, Moscow, 101000, Russian Federation

E-mail: nilysenok@hse.ru

ORCID: 0000-0003-4660-1410

Citation

Lysenok N.I. (2025) Information System Architecture for Volatility Forecasting Based on Machine Learning for Decision Support Systems. *Business Informatics*, vol. XX, no. X, pp. XX–XX. DOI: [to be assigned]